



Revisão Docker Básico




Revisão Docker Básico



Arquitetura de Dados

DEFINIÇÃO

- Uma arquitetura de dados descreve como os dados são gerenciados, desde a coleta até a transformação, a distribuição e o consumo.
- Ela define o plano para os dados e a maneira como eles irão fluir pelos sistemas de armazenamento de dados.
- A Arquitetura de dados é um subconjunto da Arquitetura Corporativa.



Arquitetura de Dados

DEFINIÇÃO

A definição da Arquitetura de Dados é baseada em basicamente 2 framework para Arquitetura de Software Corporativa:

DAMA-DMBOK 2

O Data Management Body of Knowledge, originalmente fundado como DAMA International abrange arquitetura de dados.

<https://www.dama.org/articles/introducing-the-revised-dama-data-management-body-of-knowledge-2nd-edition>

TOGAF

TOGAF (Open Group Architecture Framework) criado em 1995 pelo Open Group e é apontado com o mais usado atualmente.

<https://pubs.opengroup.org/architecture/togaf9-doc/arch/>

Arquitetura de Dados

A ERA BIG DATA

- Termo criado originalmente pela NASA em 1997.
- Desafios computacionais para lidar com grandes volumes de dados (captura, processamento, análise e armazenamento). Big Data se **refere usualmente a conjunto de dados com tamanho além da capacidade** de processamento por **ferramentas usuais** de software.
- O tamanho do que é considerado Big Data no início era por volta de poucos terabytes; hoje já são muitos **petabytes**.
- O que não é Big Data:
 - Um hardware.
 - Um Software.
 - Uma metodologia.

Arquitetura de Dados

OS V'S DO BIG DATA

O termo BIG DATA se explica através de 3Vs principais:



Arquitetura de Dados

OS V'S DO BIG DATA

Alguns autores explicam o termo usando 5Vs:



Arquitetura de Dados


ARQUITETURA DE DADOS

Existem 2 principais tipos de arquiteturas de dados para projetos Big Data:

MAIS UTILIZADA


- **ARQUITETURA LAMBDA**

Nathan Marz e James Warren - 2012



- **ARQUITETURA KAPPA**

Jay Kreps - 2014



A principal diferença entre as duas arquiteturas é o fluxo de processamento de dados envolvido.

Arquitetura de Dados

ARQUITETURA DE GERENCIAMENTO DE DADOS


1980/1990

DATA WAREHOUSE




2010

DATA LAKE




2022

DATA LAKEHOUSE



Arquitetura de Dados

ARQUITETURA DE GERENCIAMENTO DE DADOS



Arquitetura de Dados

ARQUITETURA DE GERENCIAMENTO DE DADOS

DATA WAREHOUSE + DATA LAKE = DATA LAKEHOUSE

Arquitetura de Dados

COMPARACAO ENTRE OS TIPOS DE ARQUITETURA DE GERENCIAMENTO DE DADOS

	Data Warehouse	Data Lake	Lakehouse
Armazenamento	Proprietário (BD relacional) 	Formato aberto	Formato aberto 
Tipos de Dados	Apenas dados estruturados 	Todos	Todos 
Atomicidade	Garantida com o ACID	Não Garantida 	Garantida com o ACID 
Escalabilidade	Somente Vertical 	Vertical e Horizontal	Vertical e Horizontal 
Governança	Ampla	Limitada 	Ampla 
Consumo dos Dados	Somente SQL 	Amplo (SQL, Python, Spark,...)	Amplo (SQL, Python, Spark,...) 
Machine Learning	Uso limitado 	Amplo uso	Potencializado 

Arquitetura de Dados

TIPOS DE FORMATOS DE TABELAS PARA DATA LAKE

Existem 3 frameworks para armazenamento de dados para Data Lake:

- **DELTA**
- **ICEBERG**
- **HUDI**



Apache Iceberg



Apache Hudi




Databricks Delta Lake



Arquitetura de Dados

TIPOS DE FORMATOS DE TABELAS PARA DATA LAKE

Social Stats as of Aug 2023



Arquitetura de Dados

TIPOS DE FORMATOS DE ARQUIVOS PARA DATA LAKE

DELTA LAKE, APACHE HUDI e APACHE ICEBERG são os projetos populares de código aberto que abrem caminho para o novo padrão de arquitetura Lakehouse.

A principal característica é sua capacidade de fornecer transações ACID (Atomicidade, Consistência, Isolamento e Durabilidade) para operações de leitura e gravação em Data Lakes.

***Histórias de origem** dos projetos entre 2017–2019 no Uber, Netflix e Databricks.*

<https://medium.com/@kywe665/hot-take-apache-hudi-delta-lake-apache-iceberg-are-divergent-7ca6a43d39fc>

DELTA LAKE - <https://delta.io/>

APACHE ICEBERG - <https://iceberg.apache.org/>

APACHE HUDI - <https://hudi.apache.org/>

Trabalho de Pesquisa

ARQUITETURA DE DADOS

TEMA DO TRABALHO: APACHE SPARK COM DELTA LAKE E APACHE ICEBERG

- Grupos de no máximo 3 alunos.
- Criar um único repositório/projeto público no GitHub, adicionar os participante como membros e encaminhar por e-mail para jorge.silva@satc.edu.br com o link do repo e o nome de todos os participantes **até as 22h do dia 15/04**.
- Criar um único ambiente PySpark e Jupyter Labs (podem usar o Jupyter Extensão do Visual Studio Code), implementando Delta Lake (1 arquivos .ipybnp) e Apache Iceberg (.ipybnp).
- Descrever o passo a passo para reproduzir o seu ambiente no arquivo README (instruções bem detalhadas, bibliotecas, versões, etc). Faça uso dos recursos de markdown – copy code, formatação, links, etc. Utilize IA para auxilio.

Trabalho de Pesquisa

ARQUITETURA DE DADOS

TEMA DO TRABALHO: APACHE SPARK COM DELTA LAKE E APACHE ICEBERG

- Podem utilizar como fonte de pesquisa os vídeos do canal do youtube DataWay BR.
- Projetos do github: github.com/jlsilva01/spark-delta e github.com/jlsilva01/spark-iceberg
- Utilizem o padrão de projetos Python descrito em aula (Python para Engenharia de Dados - material de apoio.pdf)
- Escolham apenas um gerenciador de projetos/pacote python e o utilizem em todo o seu projeto. POETRY ou UV.

Trabalho de Pesquisa

ARQUITETURA DE DADOS

TEMA DO TRABALHO: APACHE SPARK COM DELTA LAKE E APACHE ICEBERG

- Descreva o cenário da(s) tabela(s) em um arquivo tipo notebook – modelo ER, imagens e códigos DDL - e da fonte de dados utilizada (qualquer fonte de dados) e evidencie e explique, com exemplos, os comandos de INSERT, UPDATE e DELETE nas tabelas Delta e Iceberg dentro do Apache Spark **através do MKDOCS** (1 página web para contextualização do trabalho, 1 página web para explicar Apache Spark (pyspark), 1 página web para explicar Iceberg, 1 página web para explicar Delta). Utilizem IA para auxílio.
- Publicar o MKDOCS para uma URL publica (**mkdocs gh-deploy**)



Trabalho de Pesquisa

ARQUITETURA DE DADOS

TEMA DO TRABALHO: APACHE SPARK COM DELTA LAKE E APACHE ICEBERG

- A atividade valerá **2 pontos** em cima da Avaliação A2.
- O projeto deverá ser apresentado para o professor funcionando (10 min no máximo). Se não funcionar, fica sem nota. Se funcionar parcialmente, a nota será parcial.
- Caso o projeto funcione, será avaliado também:
 - Organização do Github,
 - Estrutura do README,
 - Documentação do MKDOCS (lembre-se README é diferente de MKDOCS, eles tem propósitos diferentes).

Prazo para entrega: 29/04.

