

Armazenamento de Dados

PRINCIPAIS TIPOS

Os três principais tipos de armazenamento de dados:

SQL



NoSQL



Arquivos




Armazenamento de Dados

ARQUIVOS

Sistema de Arquivos

- Local ou em Rede (NTFS, FAT, NAS, SAN).
- Distribuído (HDFS, Object Storage)
- Cloud (Amazon S3, Azure Data Lake Storage/Blob Storage, Google Cloud Storage).
- Responsável por gerenciar os dados no disco (escrita, armazenamento e leitura)*.
- Armazenar dados em formato de arquivo (Parquet, Avro, JSON, CSV, ORC, dentre outros).



Armazenamento de Dados

ARQUIVOS

Sistema de Arquivos Local x Distribuído

- Escalabilidade
- Disponibilidade
- Desempenho / Capacidade de Processamento
- Custo

Armazenamento de Dados

TIPO DE ARQUIVOS

Os formatos de arquivos mais comuns em Engenharia de Dados

- PARQUET
- AVRO
- ORC
- CSV
- JSON



Armazenamento de Dados

TIPO DE ARQUIVOS



Baseado em COLUNA

Baseado em LINHA

Armazenamento de Dados

FORMATO COLUNAR X FORMATO LINHA

FONTE DE DADOS

placa	modelo	chassi	marca	ano	cor
ALD3834	CLIO	34574215969	RENAULT	2011	BRANCO
CCR8096	CRETA	88547875547	HYUNDAI	2020	BRANCO
DLA3438	PUNTO	98823483434	FIAT	2013	PRETO
EEE1056	ECO SPORT	56753453455	FORD	2020	AZUL
FFR1234	PALIO	32383478747	FIAT	2020	AMARELO
GQY6753	S10	72004160549	GM	2015	PRETO
IAC8974	TIGUAN	77130757746	VOLKSWAGEN	2020	AZUL
JIE0952	PASSAT	87493270405	VOLKSWAGEN	2016	CINZA

COMO FUNCIONA O FORMATO COLUNAR E FORMATO LINHA?

Armazenamento de Dados

FORMATO COLUNAR X FORMATO LINHA

EXEMPLO DO FORMATO LINHA

placa	modelo	chassi	marca	ano	cor	
ALD3834	CLIO	34574215969	RENAULT	2011	BRANCO	Bloco/Página 1
CCR8096	CRETA	88547875547	HYUNDAI	2020	BRANCO	
DLA3438	PUNTO	98823483434	FIAT	2013	PRETO	Bloco/Página 2
EEE1056	ECO SPORT	56753453455	FORD	2020	AZUL	
FFR1234	PALIO	32383478747	FIAT	2020	AMARELO	Bloco/Página 3
GQY6753	S10	72004160549	GM	2015	PRETO	
IAC8974	TIGUAN	77130757746	VOLKSWAGEN	2020	AZUL	Bloco/Página 4
JIE0952	PASSAT	87493270405	VOLKSWAGEN	2016	CINZA	

Mais Eficiente

Leitura de 1 página

```
SELECT *  
FROM carro  
WHERE placa = 'ALD3834'
```

Menos Eficiente

Leitura de 4 páginas

```
SELECT placa, COUNT(*) as total  
FROM carro  
WHERE ano = 2020  
GROUP BY placa
```

Armazenamento de Dados

FORMATO COLUNAR X FORMATO LINHA

EXEMPLO DO FORMATO COLUNAR

placa	modelo	chassi	marca	ano	cor
ALD3834	CLIO	34574215969	RENAULT	2011	BRANCO
CCR8096	CRETA	88547875547	HYUNDAI	2020	BRANCO
DLA3438	PUNTO	98823483434	FIAT	2013	PRETO
EEE1056	ECO SPORT	56753453455	FORD	2020	AZUL
FFR1234	PALIO	32383478747	FIAT	2020	AMARELO
GQY6753	S10	72004160549	GM	2015	PRETO
IAC8974	TIGUAN	77130757746	VOLKSWAGEN	2020	AZUL
JIE0952	PASSAT	87493270405	VOLKSWAGEN	2016	CINZA

Bloco/Página 1	Bloco/Página 2	Bloco/Página 3	Bloco/Página 4	Bloco/Página 5	Bloco/Página 6
----------------	----------------	----------------	----------------	----------------	----------------

Menos Eficiente

Leitura de 6 página

```
SELECT *  
FROM carro  
WHERE placa = 'ALD3834'
```


Mais Eficiente

Leitura de 2 páginas

```
SELECT placa, COUNT(*) as total  
FROM carro  
WHERE ano = 2020  
GROUP BY placa
```


Armazenamento de Dados

TIPO DE ARQUIVOS



Armazenamento de Dados

TIPO DE ARQUIVOS

	CSV	JSON	AVRO	ORC	PARQUET
Leitura humana (capacidade)	SIM (boa)	SIM (boa)	SIM (média)	NÃO	NÃO
Paralelismo (capacidade)	SIM (ruim)	SIM (ruim)	SIM (boa)	SIM (boa)	SIM (boa)
Schema mutável (capacidade)	SIM (média)	SIM (média)	SIM (excelente)	SIM (boa)	SIM (boa)
Armazenamento	LINHA	LINHA	LINHA	COLUNA	COLUNA

A evolução do esquema é um recurso que permite aos usuários alterar facilmente o esquema atual de uma tabela para acomodar os dados que mudam com o tempo.

— Databricks.

Armazenamento de Dados

TIPO DE ARQUIVOS

Parquet

É um formato de arquivo colunar de código aberto, otimizado para processamento analítico em ambientes distribuídos com o **Apache Spark**.

Ele oferece uma compactação de dados eficiente e a capacidade de realizar leituras rápidas, especialmente para consultas analíticas.

Documentação oficial: <https://parquet.apache.org/docs/>



Armazenamento de Dados

TIPO DE ARQUIVOS

Orc

ORC (Optimized Row Columnar) é um formato de arquivo altamente otimizado para leitura de grandes conjuntos de dados.

Desenvolvido para o ecossistema Hadoop, ele combina a representação de dados em linha e em coluna (estrutura híbrida), para permitir análises rápidas e compactação superior.

Formato de arquivo preferido pelo **sistema Hadoop**.

Documentação oficial: <https://orc.apache.org/>



Armazenamento de Dados

TIPO DE ARQUIVOS

Avro

É um formato de arquivo de dados serializado, desenvolvido para o ecossistema do Apache Hadoop, que oferece eficiência na compactação e velocidade de acesso.

Projetado para lidar com dados estruturados complexos, é particularmente útil para troca de dados em sistemas distribuídos com o **Apache Kafka**.

Documentação oficial: <https://avro.apache.org/docs/>



Armazenamento de Dados

TIPO DE ARQUIVOS

Json

Arquivos neste formato contêm informações estruturadas no formato JSON (JavaScript Object Notation), comumente usados para armazenar e trocar dados entre sistemas de computador.

Muito utilizado em sistemas que usam API e bancos de dados NoSQL (MongoDB).

Documentação oficial: <https://datatracker.ietf.org/doc/html/rfc8259/>



Armazenamento de Dados

TIPO DE ARQUIVOS

Csv

CSV (Comma-Separated Values) é um formato de arquivo simples para representar dados tabulares.

Cada linha do arquivo contém registros separados por um delimitador, geralmente uma vírgula e o primeiro registro muitas vezes representa os cabeçalhos das colunas.

Documentação oficial: <https://datatracker.ietf.org/doc/html/rfc4180/>



Exercícios

Atividade Prática Sistemas de Arquivos

1. Criar uma área de armazenamento de dados local tipo object storage através de um container do Minio (*docker*).
2. Criar um sistema de armazenamento de dados em nuvem através do Terraform e Azure CLI, usando uma assinatura gratuita da Azure (*terraform, azure cli e vs code*).
3. Utilizar o DuckDB para acesso e consulta aos dados em ambos os sistemas de armazenamento de dados (*DuckDB e –opcional- DBeaver*).

Exercícios

Atividade Prática Sistemas de Arquivos

Docker Minio:

<https://hub.docker.com/r/minio/minio>

```
docker run -d -p 9000:9000 -p 9001:9001 minio/minio:RELEASE.2025-02-03T21-03-04Z server /data --console-address ":9001"
```

Docker logs <nome do container>: URL de acesso ao portal do Minio, usuário e senha.

Instalador DuckDB:

https://duckdb.org/docs/installation/?version=stable&environment=cli&platform=linux&download_method=direct&architecture=x86_64

Instalador Terraform:

<https://developer.hashicorp.com/terraform/install>

Instalador Azure CLI:

<https://learn.microsoft.com/pt-br/cli/azure/install-azure-cli-windows?tabs=zip>

Procedimento completo criação do storage account (README):

<https://github.com/jlsilva01/adls-azure/>



Exercícios

Atividade Prática Sistemas de Arquivos

Docker Minio:

<https://hub.docker.com/r/minio/minio>

```
docker run -d -p 9000:9000 -p 9001:9001 minio/minio:RELEASE.2025-02-03T21-03-04Z server /data --console-address ":9001"
```

Docker logs <nome do container>: URL de acesso ao portal do Minio, usuário e senha.

Instalador DuckDB:

https://duckdb.org/docs/installation/?version=stable&environment=cli&platform=linux&download_method=direct&architecture=x86_64

