


Projeto Spark

DEFINIÇÃO

- **Criado em 2009** na Universidade Berkley, passou para **Apache Foundation em 2014**.
- Framework de código aberto para **computação distribuída (processamento paralelo)** de dados massivos (big data).
- Utiliza linguagens Python, Scala, Java, SQL e R (Spark API).
- Processamento em memória (RDD)
Resilient Distributed Dataset
- SQL, streaming/batch, Mllib e GraphX.



Projeto Spark


DEFINIÇÃO

- **Pyspark** é uma colab entre Apache Spark e Python.




- **Databricks** criada em 2013 pelos fundadores do Spark (Berkley). Atualmente o maior colaborador para o projeto spark e a plataforma de processamento de dados massivos (modelo cloud PaaS - SaaS*) mais utilizada no mercado.
- Outras plataformas que usam Spark: Amazon EMR, Google Cloud Dataproc, Azure Synapse Analytics, Azure HDInsight.

*Modelos Cloud



*Modelos Cloud



- TABELAS GERENCIADAS (INTERNAS)

O Spark **gerencia os dados e metadados** em algum sistema de armazenamento. Seja ele local ou cloud.

- TABELAS NÃO GERENCIADAS (EXTERNAS)


O Spark gerencia **apenas os metadados**. O gerenciamento dos dados da tabela fica por conta do usuário em alguma fonte externa.

IMPORTANTE I: TABELAS NÃO GERENCIADAS são criadas quando utilizamos arquivos externos ou no próprio disco. Tabelas a partir de um dataframe, serão TABELAS GERENCIADAS.

IMPORTANTE II: Em TABELAS GERENCIADAS, comandos como DROP TABLE deletam tanto os dados quanto os metadados da tabela criada. Em TABELAS NÃO GERENCIADAS os dados são preservados e apenas o metadados é dropado.

Atividade Prática – Trabalho 2 (1 ponto)

APACHE SPARK COM MINIO e SQL



Atividade Prática – Trabalho 2 (1 ponto)

APACHE SPARK COM MINIO e SQL

1. O trabalho 2 é um complemento do trabalho 1, onde vocês deverão implementar a extração dos dados de todas as tabelas de um banco de dados (relacional ou não relacional - livre escolha) e gravar em um bucket no MinIO chamado 'landing-zone' no formato CSV (para relacional) e JSON (para não relacional).
2. Após a extração, vocês deverão ler os arquivos CSV ou JSON do bucket 'landing-zone' e gravar no formato DELTA LAKE em um novo bucket chamado 'bronze'.
3. Após a conversão para DELTA LAKE, reproduza as 3 operações de DML (insert, update e delete) feitas no trabalho anterior para as tabelas DELTA LAKE do bucket 'bronze' (não precisa usar todas as tabelas).
4. Analise as diferenças entre tabelas gerenciadas e não gerenciadas dos dois laboratórios e discuta em aula.

Atividade Prática – Trabalho 2 (1 ponto)

APACHE SPARK COM MINIO e SQL

5. IMPORTANTE: Apesar do trabalho 2 ser um complemento do trabalho 1, o trabalho deverá ser feito em NOVO REPOSITÓRIO NO GITHUB, ou seja, cada trabalho deverá ter o seu repositório no GitHub separado.

6. Utilizem esse repositório <https://github.com/jlsilva01/spark-delta-minio-sqlserver> como modelo/exemplo para desenvolvimento do trabalho 2.

7. OBSERVAÇÃO:

- Para o trabalho 2, NÃO PRECISA fazer a conversão para APACHE ICEBERG, apenas para o DELTA LAKE (para o trabalho 1 precisa ser delta e iceberg).
- O trabalho 1 e o trabalho 2 deverão ter repositórios distintos, cada um com suas pastas, bibliotecas, README e MKDOCS separados.

ENTREGA EM 06/05