


Trabalho Final

TRABALHO FINAL COM BASE EM METODOLOGIAS ATIVAS DE APRENDIZAGEM

“O projeto deverá contemplar a **construção de um pipeline de dados**, ou seja, deverá realizar a **leitura/coleta de dados** de um **ambiente de origem** a sua escolha...

...copiar para um **data Lake**, **transformar, refinar e disponibilizar os dados** em um modelo **dimensional** ou **OBT** para consumo através de um **dashboard**.”



Trabalho Final

TRABALHO FINAL COM BASE EM METODOLOGIAS ATIVAS DE APRENDIZAGEM

Premissas:

- O ambiente relacional/Não Relacional – origem – deverá ter no mínimo 10 tabelas, 10.000 linhas para cada tabela principal e com distribuição de datas para os últimos 3 anos (para que no dashboard tenha informações para compor os KPIs e métricas). Você pode utilizar bibliotecas python como faker ou outra similar para gerar massa de dados para o seu ambiente relacional.
- A ingestão dos dados deverá ser feita através de uma ferramentas de orquestração de tarefas a sua escolha. Você poderá usar local (docker) ou cloud. Não usar agendador de tarefas do Windows ou cron do Linux.
- Seu Data Lake deverá ser criado em cima de um object storage (local – docker – cloud) usando a arquitetura medalhão (camadas Landing, Bronze, Silver e Gold).
- Os dados deverão ser gravados no formato Delta Lake nas camadas Bronze, Silver e Gold. Na Landing ele deverá ser gravado no formato bruto original (CSV para SQL e JSON para NoSQL).

Trabalho Final

TRABALHO FINAL COM BASE EM METODOLOGIAS ATIVAS DE APRENDIZAGEM

Premissas:

- O motor de transformação deverá ser feito através do Apache Spark (Java, R, Scala ou Python/pyspark).
- As atividades (notebooks ou scripts) de ingestão, transformação e movimentação dos dados entre as camadas deverão ser orquestradas e agendadas através de uma ferramenta de orquestração (conforme já citado anteriormente).
- Os dados devem ser disponibilizados na camada Gold no formato dimensional (fatos e dimensões ou OBT).
- Criar 4 KPIs e 2 métricas para compor o seu dashboard através de uma ferramenta a sua escolha (dashboard padrão One Page View) – exemplo no quadro.
- O dashboard deverá consumir os dados do modelo dimensional ou OBT, direto da camada gold (se a ferramenta de dataviz assim o permitir) ou de um banco de dados relacional que possui os dados virtualizados da camada gold.

Trabalho Final

TRABALHO FINAL COM BASE EM METODOLOGIAS ATIVAS DE APRENDIZAGEM

Premissas:

- Todo o trabalho deverá ser publicado no GitHub. A documentação completa do trabalho deverá estar publicada no MkDocs. Caprichem no README.md. Usem os feedbacks dos trabalhos para construção deste item.
- Os artefatos/códigos/scripts deverão ser versionados no GitHub através de Pull Request. O repositório deverá ser configurado para que não seja possível atualizar a branch main/master diretamente sem passar por um Pull Request e suas devidas aprovações.
- Todas as atividades e tarefas deverão ser mapeadas e registradas através de issues no GitHub.
- Utilize os padrões e melhores práticas vistos na aula de “Python para Engenharia de dados” para organização do projeto dentro do GitHub.
- ~~• As cargas dos dados deverão ser feitas todas como SCD tipo 2 (incremental) para as dimensões. As tabelas fato deverão usar tabelas de checkpoint para controle da carga incremental.~~

Trabalho Final

TRABALHO FINAL COM BASE EM METODOLOGIAS ATIVAS DE APRENDIZAGEM


- Trabalho em conjunto (grupos a serem montados em sala) com avaliação **individual**.
- A avaliação será baseada na **participação de cada aluno em sala de aula e nas interações no projeto do GitHub** durante a construção do trabalho.
- A **ausência do aluno** no dia da Avaliação A3 (apresentação do trabalho) **resultará em nota zero e sem possibilidade de recuperação em outro dia ou pela N-1**.
- Um resumo de todo o trabalho deverá ser **apresentada através do Powerpoint** (ou similares) - **20 min.** de apresentação – e depois demonstrar na prática toda a jornada no dado até a visualização do dashboard (incluindo demonstração de carga incremental).
- A “entrega” do trabalho deverá ser feita através do Portal AVA com a URL do Github e a URL do MKDOCS até 24/06 às 18:59h.
- **IMPORTANTE: Não serão aceitas alterações no repositório após as 19h do dia da apresentação.**

Trabalho Final

MODELOS, TEMPLATES E SUGESTÃO DE FERRAMENTAS

<https://github.com/jlsilva01/projeto-ed-satc>

- Modelo para o README.
- Licença de uso.
- Estrutura de pastas padrão.
- Exemplos e referências para o MkDocs.



DIAGRAMAS DE MODELOS E DESENHOS DE ARQUITETURA:

- <https://excalidraw.com/>
- <https://miro.com/pt/>
- <https://app.diagrams.net/>
- <https://dbdiagram.io/home>
- <https://sqldbm.com/>

Trabalho Final

MODELOS, TEMPLATES E SUGESTÃO DE FERRAMENTAS

ATUALIZAÇÕES E PUBLICAÇÕES MKDOCS

- **MKDOCS SERVE** – Visualização temporária (localhost).
- **MKDOCS BUILD** – Cria os arquivos HTML, CSS, JS etc.
- **MKDOCS GH-DEPLOY** – Publica os arquivos no GitHub Pages (URL pública).

Trabalho Final

MODELOS, TEMPLATES E SUGESTÃO DE FERRAMENTAS

SUGESTÃO DE FERRAMENTAS



Astro CLI



Azure Data Factory



Azure
Synapse
Analytics



amazon
EMR



amazon
S3



MINIO



ADLS Gen2



Looker



Streamlit



Power BI



Apache
Superset



Metabase



Trabalho Final

Jornada do Projeto de Engenharia de Dados

Pipeline de dados • Data Lake em camadas • Spark • Dashboard • GitHub + MkDocs

1



Objetivo do Projeto

Construir um pipeline de dados completo: coletar dados de uma origem à escolha, copiar para um Data Lake, transformar, refinar e disponibilizar os dados em modelo dimensional ou OBT para consumo em dashboard.

2



Origem dos Dados

- Ambiente relacional ou não relacional
- Mínimo de 10 tabelas
- 10.000 linhas por tabela principal
- Dados distribuídos nos últimos 3 anos
- Pode usar Faker para gerar massa de dados

3



Ingestão e Orquestração

- Ingestão feita por ferramenta de orquestração
- Pode ser local (Docker) ou cloud
- Não usar Agendador do Windows nem cron do Linux
- Atividades de ingestão, transformação e movimentação devem ser agendadas/orquestradas

4

Data Lake + Arquitetura Medalhão



Landing – bruto original (CSV para SQL / JSON para NoSQL)



Bronze – Delta Lake



Silver – Delta Lake



Gold – Delta Lake



Object storage local, Docker ou cloud

5



Transformação

Motor de transformação obrigatório: Apache Spark (Java, R, Scala ou Python/PySpark).

6



Modelagem na Gold

- Disponibilizar dados em modelo dimensional (fatos e dimensões) ou OBT
- Consumido diretamente pela ferramenta de dataviz ou por banco relacional com dados virtualizados da Gold

7



Dashboard Final

- Criar 4 KPIs e 2 métricas
- Formato One Page View
- Dashboard alimentado pela camada Gold

8



Boas Práticas de Entrega

- Projeto publicado no GitHub
- Documentação completa no MkDocs
- Caprichar no README.md
- Versionamento via Pull Request
- Proteger main/master contra alterações diretas
- Registrar tarefas e atividades em Issues
- Usar padrões e boas práticas vistos em aula



Trabalho em Equipe e Avaliação



Trabalho em grupo com avaliação individual



Avaliação baseada na participação em sala e nas interações no GitHub



Apresentação com resumo em PowerPoint (ou similar)



Demonstrar a jornada completa até o dashboard, incluindo carga incremental



Tempo de apresentação: **20 min**

10

Entrega e Regras Importantes



Entrega pelo Portal AVA com URL do GitHub e URL do MkDocs



Prazo: **24/06**
às 18:59h



Ausência na apresentação (A3) = nota zero, sem recuperação em outro dia ou pela N-1



IMPORTANTE: não serão aceitas alterações no repositório após as 19h do dia da apresentação.



Sugestão de Ferramentas

Bancos de Dados

SQL PostgreSQL

Ingestão e Orquestração

Airflow Astro CLI Azure Data Factory
NiFi

Processamento

Spark PySpark

Armazenamento / Data Lake

S3 MinIO ADLS Gen2
Azure Synapse

Visualização / Dashboard

Power BI Metabase
Superset Looker Streamlit

Linguagem e Plataforma

Python Docker
Terraform VirtualBox

Formato e Tecnologia

Delta Lake
Delta Lake (Medalhão)